스프린트 미션 16

딥러닝 모델 변환과 양자화

1. 개요

- 이전에 학습했던 미션 10의 '뉴스 기사 카테고리 분류 LSTM 모델'을 다양한 포맷(pth, 양자화 pth, onnx)으로 변환 및 저장하였습니다.
- ONNX 포맷으로 변환한 모델을 불러와 평가 데이터셋으로 추론을 검증하는 실습을 수행하였습니다.

2. 선택한 데이터셋 및 모델

- 데이터셋: 20 Newsgroups (20개의 주제로 분류된 영문 뉴스 텍스트 데이터)
- 모델 구조: FastText + LSTM
  - 단어의 의미적 특성을 반영하기 위해 FastText(Vector Size: 128) 임베딩 레이어를 구성했습니다.
  - 시퀀스 데이터의 문맥을 파악해 최종 카테고리를 분류하기 위해 LSTM 아키텍처를 채택했습니다.
- 학습 방식: 사전학습 모델을 파인튜닝(Fine-tuning)하지 않고, 데이터셋에 맞춰 임베딩 행렬 초기화부터 분류기까지 직접 아키텍처를 구성하여 학습을 진행했습니다.

3. 실습 및 구현 과정 요약

1. 기본 모델 저장 (.pth): 모델 학습 완료 후 `torch.save`를 활용해 원본 모델의 가중치(FP32)를 저장했습니다.
2. 모델 양자화 (Dynamic Quantization): 서비스 환경에서의 추론 속도 향상과 메모리 절감을 위해, `torch.quantization.quantize_dynamic`을 적용하여 모델의 선형 레이어 가중치를 8비트 정수형(INT8)으로 압축했습니다.
3. ONNX 포맷 변환 (.onnx): 플랫폼 독립적인 배포를 위해 `torch.onnx.export`를 사용하여 양자화된 모델을 ONNX 포맷으로 추출했습니다. 가변 시퀀스 처리를 위해 `dynamic_axes`를 설정하여 배치 사이즈를 유동적으로 받을 수 있도록 구성했습니다.
4. 전처리 객체 저장: 추론 시 입력 데이터 전처리를 위해 사용되는 커스텀 단어장(`word2idx_fasttext`)을 `pickle` 라이브러리로 추출하여 `.pkl` 파일로 저장했습니다.

4. ONNX 기반 모델 추론 및 결과

- 파이토치 의존성 없이 onnxruntime 엔진과 순수 NumPy만을 사용하여 추론 환경을 구축했습니다.
- 테스트 결과: NASA의 제임스 웹 우주 망원경 관련 영문 기사를 테스트 데이터로 입력한 결과, 20개의 카테고리 중 sci.space (우주 과학) 카테고리를 정확하게 예측했습니다.
- 성능 지표: 단일 문장 추론 기준 약 0.015초 내외의 매우 빠른 추론 응답 속도를 확인했습니다.

```
•••  예측 카테고리: sci.space
     카테고리 인덱스: 14
     추론 소요 시간: 0.0152초
```

5. 트러블슈팅 및 이슈 해결

- ONNX 변환 엔진 호환성 이슈 (torch.onnx & onnxscript)

  Issue: PyTorch 모델을 ONNX로 변환하는 과정에서 최신 백엔드인 `onnxscript`를 지원하지 않는 환경/버전 충돌 에러가 발생했습니다.

  Solution: 변환 방식을 조정하여 기존의 표준 Tracing/Scripting 방식을 사용하도록 우회함. 특히 가변 길이 시퀀스를 처리하는 LSTM의 특성상 `dynamic_axes` 설정 시 발생할 수 있는 Shape 불일치를 방지하기 위해 입출력 텐서의 구조를 명확히 정의하여 성공적으로 추출했습니다.

6. 최종 파일/모델 구조 및 용량 확인

최적화 단계를 거치며 모델의 파일 용량이 유의미하게 감소하는 것을 확인했습니다.

이름	수정일	크기	종류
mission_10_lstm_model.onnx	오늘 오후 1:43	94KB	문서
mission_10_lstm_model.onnx.data	오늘 오전 11:27	55.2MB	문서
mission_10_lstm_model.pth	오늘 오후 1:42	55.2MB	문서
mission_10_lstm_quantized.pth	오늘 오후 1:42	53.2MB	문서